

MW 1

Batch of images: $[B \times C \times M \times W]$, $M=W=S$

FLOPs

Нейронов
на
выходе

Цена (1 MAC = 2 FLOPs)
одного

FLOPs

conv1 7×7 $S=2$	$8BS^2$	147 MAC (3.77)		$2352 \cdot B \cdot S^2$
bn1	$8BS^2$	1 MAC (a.x+b)		$16BS^2$
relu	$8BS^2$	1 сравнение		$8BS^2$
maxpool 3×3 , $S=2$	$2BS^2$	8 сравнений		$16BS^2$
conv2 5×5 ($32 \rightarrow 64$)	$4BS^2$	800 MAC		$6400BS^2$
bn2	$4BS^2$	1 MAC		$8BS^2$
relu	$4BS^2$	1 сравнение		$4BS^2$
conv3 3×3 , $S=2$ ($64 \rightarrow 128$)	$2BS^2$	576 MAC		$2304BS^2$
bn3	$2BS^2$	1 MAC		$4BS^2$
relu	$2BS^2$	1 сравнение		$2BS^2$
conv4 1×1 ($128 \rightarrow 256$)	$4BS^2$	128 MAC		$1024BS^2$
bn4	$4BS^2$	1 MAC		$8BS^2$
relu	$4BS^2$	1 сравнение		$4BS^2$
conv5 3×3 , $S=2$	$1BS^2$	2304 MAC		$4608BS^2$
bn5	$1BS^2$	1 MAC		$2BS^2$
relu	$1BS^2$	1 сравнение		BS^2
conv6 1×1	$2BS^2$	256 MAC		$1024BS^2$
bn6	$2BS^2$	1 MAC		$4BS^2$
relu	$2BS^2$	1 сравнение		$2BS^2$
Global AvgPool	$512B$	$(\frac{S}{16})^2$ сложений + $\frac{S}{16}$ умножений		$2BS^2$
flatten	$512B$	0		0
fc1	$256B$	512 MAC		$262144B$
relu	$256B$	1 сравнение		$256B$
fc2	$100B$	256 MAC		$51200B$

$$FLOPs(S, B) = 17793B \cdot S^2 + 156672B$$

FLOPs

Memory

Layer	Хранимых чисел
CONV1 $7 \times 7, 3 \rightarrow 32$	$C_{out} \cdot C_{in} \cdot k \cdot k = 4704$
CONV2 $5 \times 5, 32 \rightarrow 64$	51200
CONV3 $3 \times 3, 64 \rightarrow 128$	73728
CONV4 $1 \times 1, 128 \rightarrow 256$	32768
CONV5 $3 \times 3, 256 \rightarrow 256$	589824
CONV6 $1 \times 1, 256 \rightarrow 512$	131072
$b_{n1}, \dots, b_{n6}$ ($V, B, running_mean, running_var$)	$4C=4992, C=32+64+128+256+256+512=1248$
fc1 $512 \rightarrow 256$	$512 \cdot 256 + 256 = 131328$
fc $256 \rightarrow 100$	$256 \cdot 100 + 100 = 25700$

$\leq 1045316 \cdot 4 \text{ байт} \approx 4 \text{ МБ}$
веса модели

Активации: предположим, что все активации находятся в памяти одновременно.

input	$3 \cdot S^2 \cdot B$
conv1, b_{n1}	$16 \cdot S^2 \cdot B$
maxpool	$2 \cdot S^2 \cdot B$
conv2, b_{n2}	$8 \cdot S^2 \cdot B$
conv3, b_{n3}	$4 \cdot S^2 \cdot B$
conv4, b_{n4}	$8 \cdot S^2 \cdot B$
conv5, b_{n5}	$2 \cdot S^2 \cdot B$
conv6, b_{n6}	$4 \cdot S^2 \cdot B$
GlobalAvgPool	$512B$

Чисел, хранимых в памяти при forward pass batch'a

fc1
&c2

256B
100B

$$\sum 47 \cdot B \cdot S^2 + 868 B$$

$$\text{Memory}(S, B) = \underbrace{4181312}_{W} \text{ байт} + 4 \cdot B \underbrace{(47 \cdot S^2 + 868)}_{\text{activations}}$$

Bytes moved (VRAM $\Rightarrow$ Выходящие аргы)

	Читает	Пишет	Вес	Уровни байт
conv1 7x7 $3 \rightarrow 32$ $S=2$	$8S^2$	$32 \cdot \frac{S}{2} \cdot \frac{S}{2} = 8S^2$	4704	$44 \cdot B \cdot S^2 + 18816$
bn1	$8S^2$	$8S^2$	128	$64BS^2 + 512$
relu	$8S^2$	$8S^2$	-	$64B \cdot S^2$
maxpool 3x3, $S=2$	$8S^2$	$2S^2$	-	$40B \cdot S^2$
conv2 5x5 ($32 \rightarrow 64$)	$2S^2$	$4S^2$	51200	$24BS^2 + 204800$
bn2	$4S^2$	$4S^2$	256	$32 \cdot B \cdot S^2 + 1024$
relu	$4 \cdot S^2$	$4S^2$	-	$32B \cdot S^2$
conv3 3x3, $S=2$ ($64 \rightarrow 128$)	$4 \cdot S^2$	$2S^2$	73728	$24 \cdot B \cdot S^2 + 294912$
bn3	$2S^2$	$2S^2$	512	$16BS^2 + 2048$
relu	$2S^2$	$2S^2$	-	$16BS^2$
conv4 1x1 ($128 \rightarrow 256$)	$2S^2$	$4S^2$	32768	$24BS^2 + 131072$
bn4	$4S^2$	$4S^2$	1024	$32BS^2 + 4096$
relu	$4S^2$	$4S^2$	-	$32BS^2$
conv5 3x3, $S=2$	$4S^2$	S^2	589824	$20BS^2 + 2353296$
bn5	S^2	S^2	1024	$8BS^2 + 4096$
relu	S^2	S^2	-	$8BS^2$
conv6 1x1	S^2	$2S^2$	131072	$12BS^2 + 524288$
bn6	$2S^2$	$2S^2$	2048	$16B \cdot S^2 + 8192$
relu	$2S^2$	$2S^2$	-	$16BS^2$
Global AvgPool	$2S^2$	512	-	$8BS^2 + 2048B$
flatten	0	0	-	0
fc1	512	256	131328	$3072B + 525312$
relu	256	256	-	2048B
fc2	256	100	25700	$1424B +$ $+102800$

Итого: $\text{Bytes}(S, B) = 532 \cdot B \cdot S^2 + 8592 B + 4181 \cdot 264$
байт

$\text{Latency}(S, B, \Theta) = \sum t_i,$

где $t_i = t_{\text{launch}} + \max\left(\frac{\text{FLOPs}_i}{P}, \frac{\text{Bytes}_i}{BW}\right)$

- FLOPs_i - номер операции из таблицы FLOPs
- Bytes_i - из Bytes moved
- $\Theta = (t_{\text{launch}}, P, BW)$

Введем понятие арифметической интенсивности:

$I_i = \frac{\text{FLOPs}_i}{\text{Bytes}_i}$ из наших таблиц в зависимости от слоя

И рассмотрим пиковую I_{max} по спецификациям T4 (выбранная GPU): $\frac{8.1 \cdot 10^{12} \text{ FLOPs/sec}}{320 \cdot 10^9 \text{ bytes/sec}} \approx 25$

Итого, если $I_i > 25 \rightarrow \text{compute-bound} \approx 25 \text{ FLOPs/byte}$

$I_i < 25 \rightarrow \text{memory-bound}$

↓↓ см. ниже

conv1
bn1
relu
maxpool
conv2
bn2
relu

conv3

bn3

relu

conv4

bn4

relu

conv5

bn5

relu

conv6

bn6

relu

Global AvgPool

flatten

fc1

relu

fc2

I_i при больших B, S

53

0,25

0,125

0,4

267

0,25

0,125

96

0,25

0,125

43

0,25

0,125

230

0,25

0,125

85

0,25

0,125

0,25

—

51 (если $B=256$)

0,125

28 ($B=256$)

Compute-bound, начиная с:

$B \cdot S^2 > 376$

—

—

$B \cdot S^2 > 883$

—

$B \cdot S^2 > 4327$

—

$B \cdot S^2 > 7728$

—

$B \cdot S^2 > 14358$

—

$B \cdot S^2 > 18104$

—

—

—

—

$B > 71$

—

$B > 165$

$$\text{Energy}(S, B, \Theta) = e_{\text{flop}} \cdot \text{FLOPs}(S, B) + e_{\text{byte}} \cdot \text{Bytes}(S, B) + P_{\text{static}} \cdot \text{Latency}(S, B, \Theta)$$

$$\bullet e_{\text{flop}} = \frac{P_{\text{clk}}}{\text{FLOP}}$$

$$\bullet e_{\text{byte}} = \frac{P_{\text{clk}}}{\text{byte}}$$

$$\bullet P_{\text{static}} = \text{Br GPU} (P_{\text{clk}} / \text{сек})$$

$$\bullet \Theta = (e_{\text{flop}}, e_{\text{byte}}, P_{\text{static}})$$

$$\begin{aligned} \text{Energy} = & e_{\text{flop}} \cdot (17793 \cdot B \cdot S^2 + 313600 B) + \\ & + e_{\text{byte}} (532 \cdot B \cdot S^2 + 8592 B + 4181264) + \\ & + P_{\text{static}} \cdot \text{Latency}(S, B, \Theta) \end{aligned}$$

- При маленьких S и B мы достигнем launch-bound.

GPU потребляет мощность, пока ждет запуска ядер, не делая полезной работы

- Энергия на одну картинку падает с ростом B .