Super-Convergence: Very Fast Training of Neural Networks Using Large Learning Rates

Leslie N. Smith, Nicholay Topin · arXiv:1708.07120v3, 2018

Разбор статьи и воспроизведение на MNIST и CIFAR-10

Зачем это нужно

- Обучение сети требует многих проходов по данным. При фиксированной модели и батче стоимость растёт с числом обновлений весов.
- **Learning rate (LR)** задаёт размер обновления. Слишком малый шаг замедляет обучение, слишком большой может сделать его неустойчивым.
- **Вопрос статьи:** можно ли временно использовать гораздо больший LR и получить сопоставимую точность за меньшее число шагов?
- **Super-convergence:** на некоторых режимах цикл LR сокращает обучение в несколько раз и иногда улучшает точность на тесте.
- Эксперименты проведены с **LeNet на MNIST** и **ResNet-56 на CIFAR-10**.

Метод: циклический learning rate

Упрощённый шаг SGD: **новые веса = старые веса – LR × градиент**.

$$w \leftarrow w - \eta \nabla L(w)$$

- **Подъём LR.** Сеть начинает с умеренных шагов, затем размер обновления растёт линейно до выбранного максимума.
- **Спад LR.** После максимума шаг уменьшается, чтобы сеть могла уточнить найденное решение.
- **1cycle.** В конце одного цикла LR опускается на несколько порядков ниже начального значения.
- **Важное различие:** опыт ResNet-56 из рис. 1a использует треугольный CLR без такого хвоста. Для MNIST воспроизведён 1cycle.

Почему большой LR может работать

Квадратичное приближение функции потерь вдоль градиента g:

$$L(w - \eta g) \approx L(w) - \eta \|g\|^2 + \tfrac{1}{2}\eta^2 g^T H g$$

H — матрица вторых производных, то есть локальная кривизна потерь.

- **Размер шага зависит от кривизны.** При слабой кривизне вдоль движения допустим больший LR. При сильной квадратичный член быстро растёт.
- **Объяснение авторов:** большой LR действует как регуляризация. Другую регуляризацию, например weight decay, нужно согласовать с ним.

Процедура статьи

- **LR range test.** Запустить короткое обучение и постепенно увеличивать LR. Проследить, в каком диапазоне качество остаётся высоким.
- **Выбор диапазона.** Назначить границы LR и длину цикла для конкретной архитектуры и данных.
- **Согласование регуляризации.** Проверить weight decay, batch size и momentum. Большой LR меняет общий уровень регуляризации.
- **Основное обучение.** Провести один цикл и сравнить точность и затраты с обычным расписанием LR.

Результаты статьи

Данные и модель	Обычное обучение	Цикл LR
CIFAR-10 / ResNet-56	80 000 шагов 91,2% (максимум)	10 000 шагов 92,4% (финал)
MNIST / LeNet	85 эпох 99,03 ± 0,04%	12 эпох 99,25 ± 0,03%

- **Главное наблюдение:** сопоставимое или более высокое качество при существенно меньшем числе обновлений.
- Авторы также проверяют другие ResNet, Wide ResNet, DenseNet и ImageNet.

Постановка

Параметр	MNIST / LeNet	CIFAR-10 / ResNet-56
Обучение / тест	60 000 / 10 000	50 000 / 10 000
Батч	512	1000
Baseline	10 000 шагов ≈ 85 эпох	80 000 шагов = 1600 эпох
Цикл LR	1407 шагов ≈ 12 эпох	10 000 шагов = 200 эпох
Повторы	3 seed на каждый режим	1 seed на каждый режим
Дополнительный опыт	Baseline на 1407 шагах	Срез baseline на 10 000 шагах

GPU: NVIDIA RTX PRO 6000 Blackwell Server Edition. PyTorch 2.10.0, CUDA 12.8.
Вычисления FP32, без AMP и TF32.

Перенос авторского кода из Caffe в PyTorch

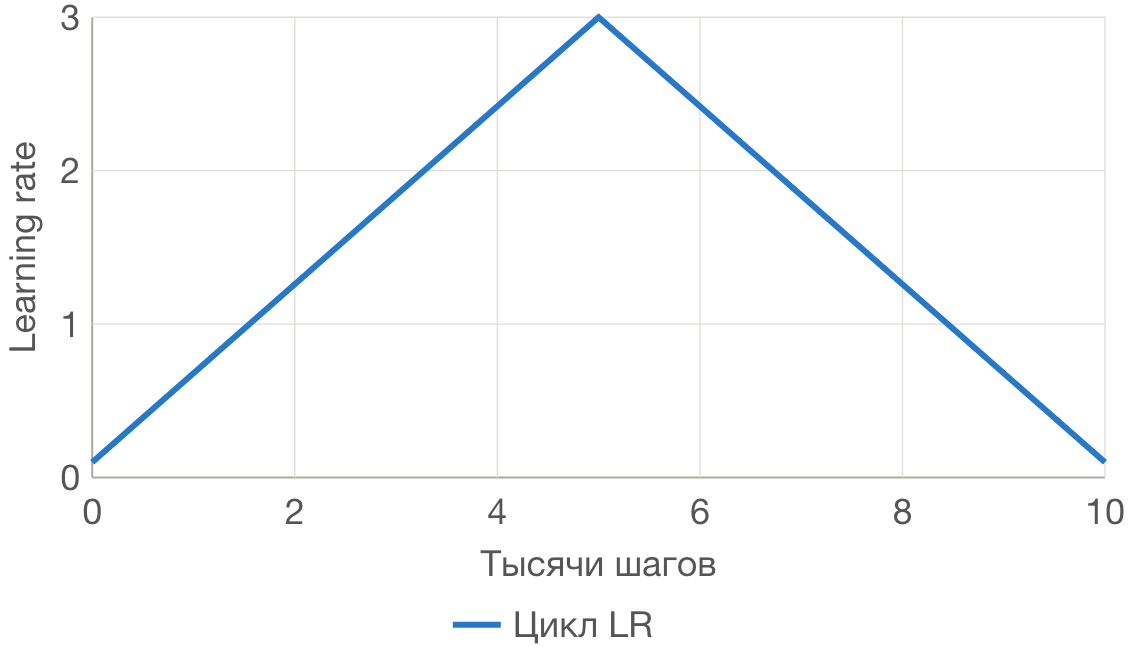
- **Архитектура.** Перенесён авторский ResNet-56: 808 682 параметра и 27 остаточных блоков. Переходы между группами отличаются от типичной реализации ResNet.
- **SGD.** В Caffe learning rate входит в буфер momentum. Поэтому при меняющемся LR его правило обновления воспроизведено отдельно.

$$v \leftarrow \mu v + \eta(g + \lambda w), \qquad w \leftarrow w - v$$

- **BatchNorm.** У авторов общий batch 1000 делится на 8 GPU по 125. На одной GPU статистики считаются в восьми группах по 125 примеров.
- **Данные.** Сохранена авторская обработка CIFAR: вычитание среднего изображения и случайное горизонтальное отражение, без дополненного crop.

Расписания LR в экспериментах

CIFAR-10: CLR

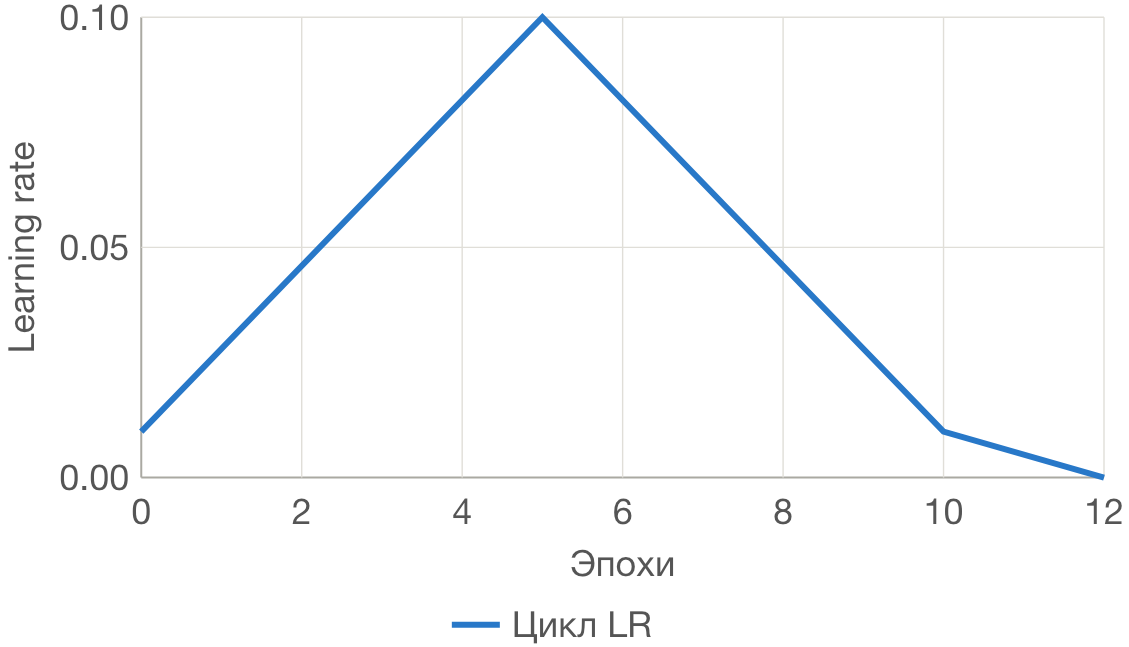


Momentum: 0,9, постоянный.

BN decay: 0,999 у baseline и 0,95 у CLR.

Baseline: LR 0,35, спад ×0,1 на 50k и 70k.

MNIST: 1cycle



Momentum: 0,95 / 0,80 / 0,95.

Конечный LR 10^{-5}: допущение воспроизведения.

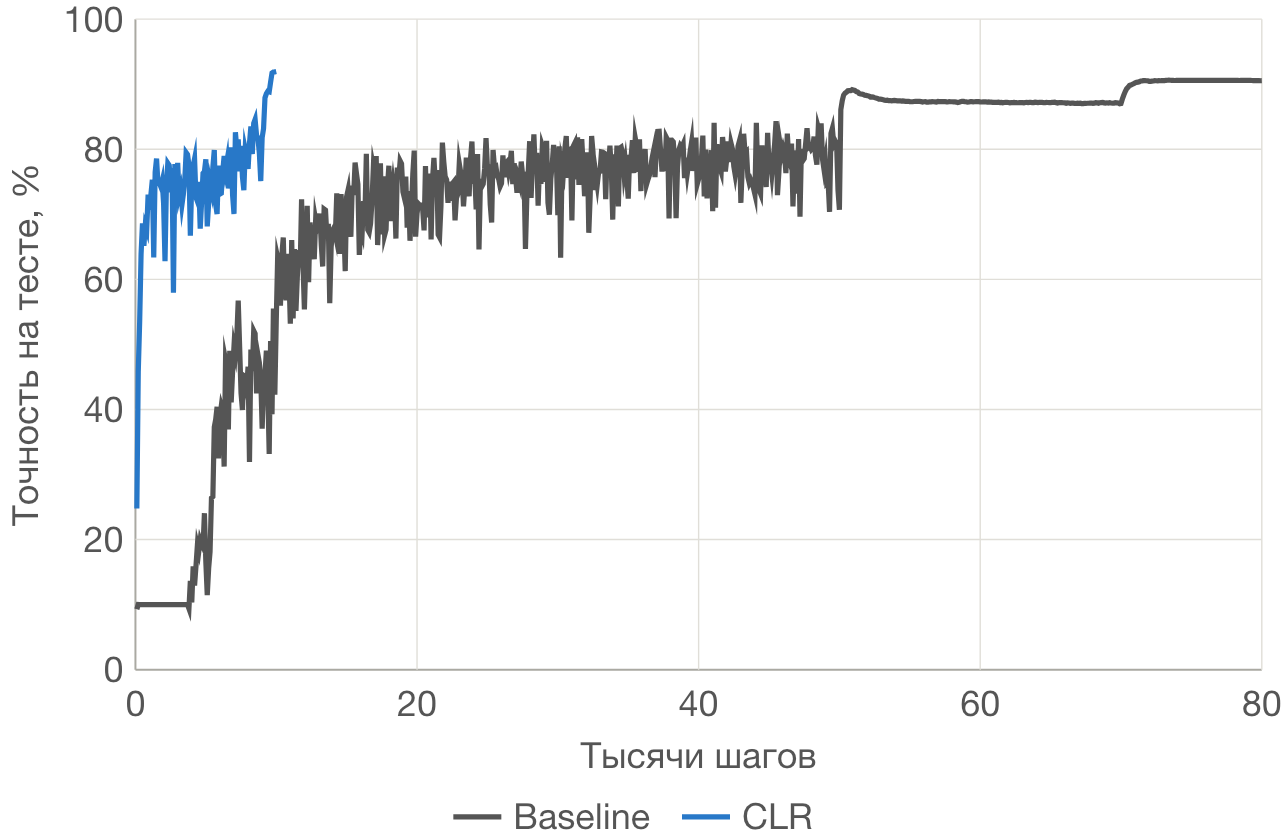
Baseline: inverse LR, начало 0,01.

Результат 1. ResNet-56 на CIFAR-10

Полные бюджеты, 1 запуск на режим.
Точность на последнем шаге.

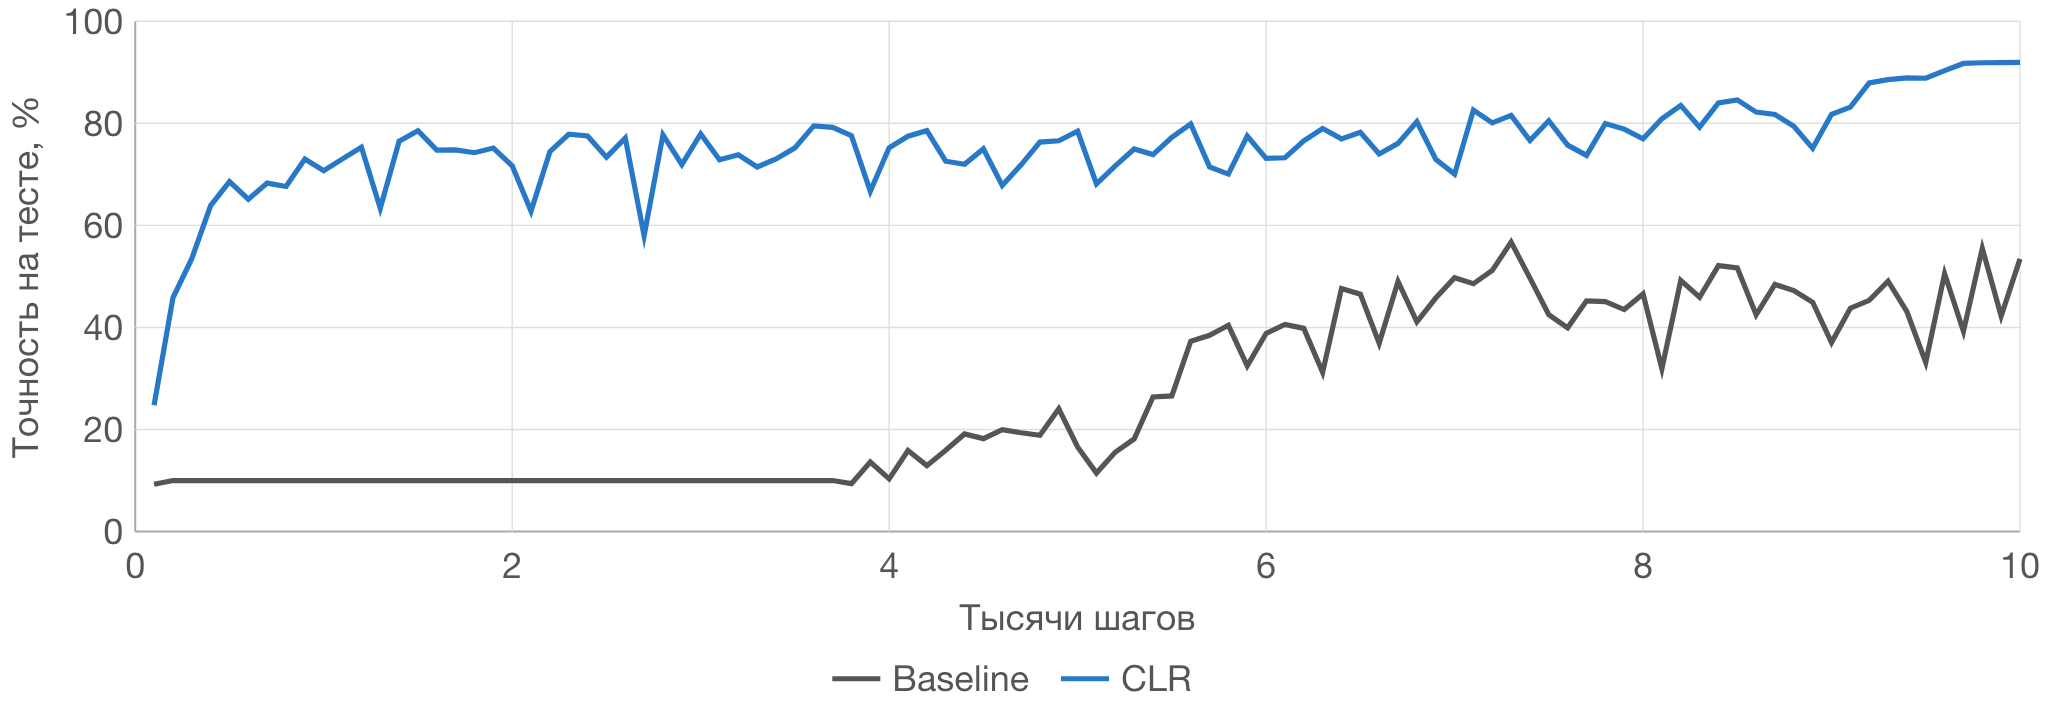
Режим	Шаги	Точность
Baseline	80 000	90,54%
CLR	10 000	91,95%

- **CLR выше на 1,41 п. п.** при восьмикратно меньшем числе шагов.
- Результат относится к двум полным протоколам: вместе с LR меняется **BN decay**.



Результат 2. Одинаковое число шагов

CIFAR-10, 10 000 шагов. Срез тех же обучений, без дополнительных запусков.

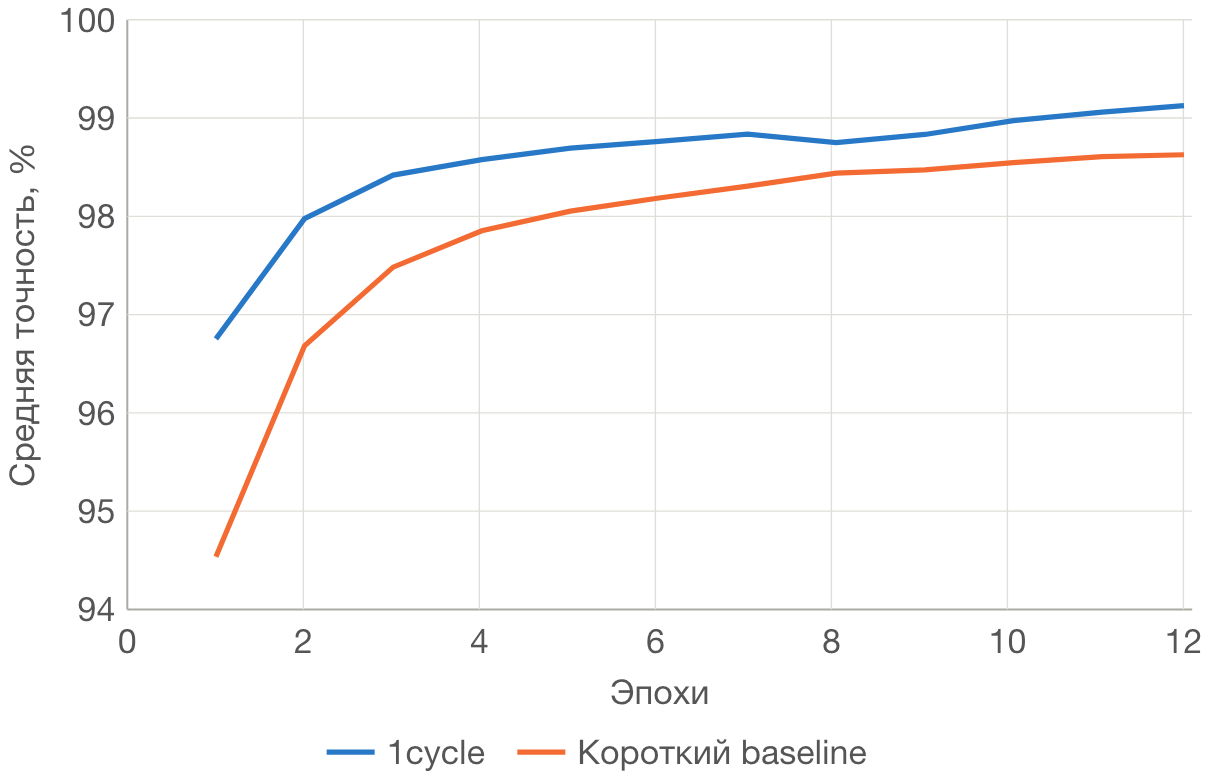


- К концу бюджета: **91,95% у CLR** против 53,43% у baseline.
- Baseline рассчитан на 80 000 шагов. Показано начало этого запуска. Отдельной настройки короткого обучения не было.

Результат 3. LeNet на MNIST

3 seed на режим. В таблице финальная точность, среднее ± SD.

Режим	Шаги	Точность, %
Baseline	10 000	99,02 ± 0,05
1cycle	1407	99,13 ± 0,04
Короткий baseline	1407	98,63 ± 0,05

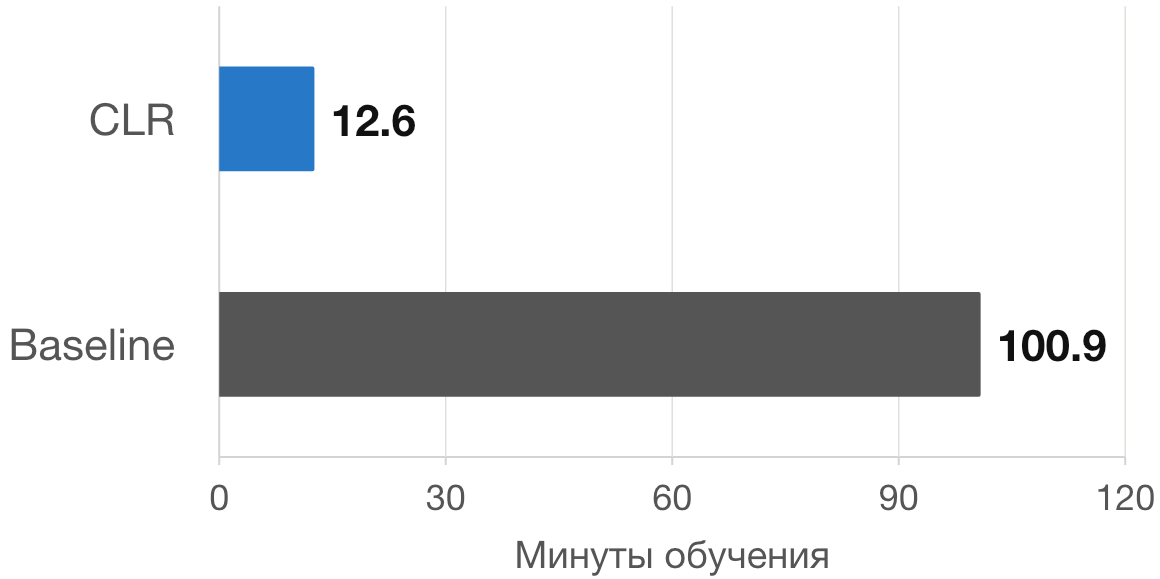


- **7,1 раза меньше шагов**: качество 1cycle сопоставимо с длинным baseline.
- При равных 1407 шагах 1cycle выше короткого baseline на **0,50 п. п.**

Результат 4. Время обучения

CIFAR-10, одна GPU. Время выполнения шагов, без оценки и сохранения.

Бюджет	Baseline	CLR
Полный протокол	100,9 мин	12,6 мин
Первое ≥ 90% в логах	89,4 мин	12,1 мин



- Полные протоколы отличаются по времени в **8,0 раза**. Стоимость одного шага близка.
- Первое измерение ≥ 90%: **7,4 раза**. Точный момент между измерениями неизвестен.

Сопоставление с результатами статьи

Сравнение	Статья	Воспроизведение
CIFAR baseline, максимум	91,2%	90,63%
CIFAR CLR, финал	92,4%	91,95%
MNIST baseline, финал	99,03 ± 0,04%	99,02 ± 0,05%
MNIST 1cycle, финал	99,25 ± 0,03%	99,13 ± 0,04%

- **Направление эффекта совпало:** цикл LR достигает сопоставимого качества за меньший бюджет.

Что сохранено для проверки

- **Конфигурации запусков:** модель, данные, seed, настройки обучения и сведения о GPU и версиях библиотек.
- **Логи обучения:** шаг, LR, momentum, train/test loss и accuracy, накопленное время обучения и оценки.
- **Исходный код и сводки:** код, с которым прошли запуски, финальные JSON и журналы результатов.

Код, исходные логи, графики и отчёт находятся в каталоге hw2.

Выводы

- **CIFAR-10:** 91,95% у CLR за 10 000 шагов против 90,54% у baseline за 80 000. Время самих шагов: 12,6 против 100,9 минуты.
- **MNIST:** 99,13 ± 0,04% у 1cycle за 1407 шагов против 99,02 ± 0,05% у baseline за 10 000. Это среднее и SD по трём seed.
- **Основной эффект воспроизвёлся:** в выбранных опытах цикл LR дал сопоставимое или лучшее качество за существенно меньшее число обновлений.

Ссылки

- **Smith L. N., Topin N.** Super-Convergence: Very Fast Training of Neural Networks Using Large Learning Rates. arXiv:1708.07120v3, 2018.
- **Статья:** arxiv.org/abs/1708.07120v3
- **Код авторов (Caffe):** github.com/lnsmith54/super-convergence
- **Код и результаты воспроизведения:** каталог hw2: конфигурации, metrics.csv и summary.json каждого запуска.
- **Подробный протокол и результаты:** отчёт report.pdf.